

Ian Carlo Carmona Serrano

AI Engineer | Agentes LLM en producción

Ciudad de México, México | iancarlocs@gmail.com | +52 55 7852 0955
linkedin.com/in/engineeria-ian-carmona | github.com/IanCarmona

PERFIL PROFESIONAL

AI Engineer con agentes conversacionales corriendo en producción y clientes de pago. Construí y opero un agente LangGraph sobre WhatsApp Business Platform que resuelve agendamiento, cobros y consultas de negocio de forma autónoma. Antes implementé RAG en un sistema conversacional para el sector financiero. En paralelo diseño pipelines bajo arquitectura Medallion en Databricks para una afore. Mi foco: sistemas LLM confiables y baratos — evals, control de alucinaciones y optimización de costo por token.

EXPERIENCIA LABORAL

AI Engineer

Amyra

Noviembre 2025 – Presente

Ciudad de México — amyra.com.mx

- Construí de cero un agente conversacional sobre LangGraph y Claude, integrado a WhatsApp Business Platform, que gestiona agendamiento, recordatorios, venta de membresías y consultas del negocio sin intervención humana. Producto en producción con clientes de pago bajo suscripción.
- Reduje el costo por mensaje del agente en 70%, de \$1 USD por cada 10 mensajes a \$1 USD por cada 30, mediante migración de modelo, prompt caching, poda de contexto y rediseño de prompts. En turnos con caché activo el costo baja a \$1 por cada 60 mensajes.
- Implementé un set de evals sobre conversaciones reales midiendo groundedness y consistencia entre corridas, reduciendo alucinaciones antes de que llegaran al usuario final.
- Migré la base de datos a Cloud SQL en GCP y opero el stack completo: frontend, backend, APIs e infraestructura. Defino el roadmap técnico y las decisiones de producto.

Data Engineer

Profuturo

Julio 2025 – Presente

Ciudad de México

- Automaticé la generación y validación de archivos regulatorios COSAR, eliminando más de 4 horas de procesamiento manual diario y el riesgo de error humano en entregables con implicaciones regulatorias.
- Construyo pipelines bajo arquitectura Medallion en Databricks con ingesta multi-cloud, como parte de la iniciativa FinOps que habilitó visibilidad del gasto tecnológico a nivel dirección vía Power BI.
- Diseño modelos dimensionales con énfasis en trazabilidad, gobernanza y calidad del dato.
- Automatizo procesos de reporting interno, reduciendo tiempos de entrega y fricción operativa entre áreas.

AI Engineer

Romboworks

Enero 2024 – Octubre 2024

Ciudad de México

- Desarrollé un sistema conversacional para el sector financiero integrando LLMs y técnicas de PLN, participando en la definición de la arquitectura funcional del producto.
- Implementé RAG con base de datos vectorial para optimizar la recuperación de contexto, incrementando 30% la precisión de las respuestas del modelo.
- Construí el frontend y la lógica de negocio con React y Node.js, iterando con el equipo de PLN sobre la calidad de las respuestas.

EDUCACIÓN

Ingeniería en Inteligencia Artificial

Instituto Politécnico Nacional (IPN) – ESCOM, Ciudad de México

Egresado | Titulación en proceso

HABILIDADES TÉCNICAS

- **IA aplicada:** LangGraph, LangChain, Claude, OpenAI, RAG, bases de datos vectoriales, prompt engineering, prompt caching, evals, agentes en producción, PLN, Machine Learning, Deep Learning
- **Data & Analytics:** Databricks, PySpark, ETL/ELT, arquitectura Medallion, modelado dimensional, Pandas, NumPy, Power BI
- **Lenguajes y Frameworks:** Python, SQL, JavaScript/TypeScript, React, Next.js, Node.js, NoSQL
- **Cloud e Infraestructura:** GCP (Cloud SQL, Cloud Functions), Azure AI Foundry, AWS, Git, Supabase
- **Integraciones:** WhatsApp Business Platform, Clerk, WorkOS

CERTIFICACIONES, FORMACIÓN E IDIOMAS

- **Certificaciones:** Databricks Data Engineer Associate (2025) | Databricks Data Analyst Learning Path (2025)
- **Formación:** Microsoft Learn — Desarrollo de agentes de IA en Azure; Desarrollo de aplicaciones de IA generativa en Azure (2026). Platzi/Udemy — 6 cursos en ETL, ingeniería de datos, PLN y BI.
- **Idiomas:** Español (nativo) | Inglés (B2, intermedio alto)